

2026 年第二届重庆市 AI 大模型创新应用大赛

三场景竞赛评测报告

制药成本智能分析系统

100.00%	100.00%
报告结构完整度	对标三步法格式正确率
100.00%	94.33 / 100
RPA 触发成功率	内部归因预评

客观技术验收：PASS

评测日期 2026-09-03

评测性质 客观技术验收与内部人工预评

官方成绩 以赛事评委评分为准

评测结论摘要

结论：

三个指定场景全部通过自动评测。报告结构完整度、对标分析三步法输出格式正确率和模拟 RPA 触发成功率均为 100.00%；真实通义千问黄金验收 3/3 通过；内部人工归因预评平均 94.33 分。

表 1 测评结果总表

赛题评测指标	结果	判定
报告结构完整度	9/9，100.00%	PASS
归因合理性评分（人工）	94.33/100	-
RPA 触发成功率	3/3，100.00%	PASS
对标三步法格式正确率	9/9，100.00%	PASS

证据文件：

- （1）确定性评测：output/evaluation/三场景自动评测结果_V1.4.json
- （2）大模型评测：output/evaluation/三场景大模型自动验收结果_20260824.json
- （3）端到端验收：output/evaluation/端到端验收结果_20260824_最终.json

一、评测范围与方法

本报告对应赛题要求的三个指定分析场景，并覆盖报告结构完整度、归因合理性评分（人工）、RPA 触发成功率、对标分析三步法输出格式正确率四项必测指标。

- 1. 报告契约状态、107 个字段、5 张受保护动态表和 1 张受控建议表；
- 2. 黄金金额、百分比、贡献度及两厂差异；
- 3. 必需证据、缺失指标“暂无数据”和 8 类知识引用；
- 4. 采购因果、设备故障错误因果等禁用结论；
- 5. 受控改进建议、来源追溯、人工审批门和模拟 RPA HTTP 提交；
- 6. 对标三步法：差异总览、成本差异结构拆解、归因分析与改进建议；
- 7. 实际调用通义千问后，100 个非叙述字段、确定性事实表、知识引用和黄金数值不被修改。

二、总体自动评测结果

表 2 总体自动测评结果表

指标	结果	判定
指定场景自动评测	3/3	PASS
报告结构完整度	9/9，100.00%	PASS
对标三步法格式正确率	9/9，100.00%	PASS
模拟 RPA 成功触发	3/3，HTTP 200	PASS
报告字段	每场景 107/107	PASS
动态表格	每场景 6/6	PASS
受治理知识引用	每场景 8/8	PASS
真实大模型黄金验收	3/3，共 105 项	PASS
全量单元与集成回归	213 项：211 通过，2 跳过	PASS

RPA 测试边界：

三个 RPA 任务使用明确标注的竞赛评测专用身份，未冒用真实企业账号；模拟服务停止后，内存任务不会进入生产系统。

三、报告结构完整度评测

每个场景检查报告契约、字段与动态表、知识引用三项结构要求，共 9 项。

表 3 三份报告结构完整度测评表

场景	报告契约	107 字段与 6 张动态表	8 类知识引用	结果
银黄口服液 2026-05	完整	完整	完整	3/3
板蓝根颗粒 2026-05	完整	完整	完整	3/3
六味地黄胶囊 2026-03	完整	完整	完整	3/3

四、对标分析三步法格式评测

Step1) 对标差异总览

输出单位成本、直接材料、直接人工、制造费用 4 行，以及本厂、对标厂、差异金额、差异率、评价等 6 列。

Step2) 成本差异结构拆解

按“总差异—三项成本要素—材料明细”展开，明确有利、不利及对标明细缺失边界。

Step3) 归因分析与改进建议

输出总体差异、原因研判、证据边界和受控整改候选，并保留人工审批后才可发送 RPA 的控制门。

表 4 三份报告三步法格式测评表

场景	第 1 步	第 2 步	第 3 步	正确率
银黄口服液 2026-05	PASS	PASS	PASS	100%
板蓝根颗粒 2026-05	PASS	PASS	PASS	100%
六味地黄胶囊 2026-03	PASS	PASS	PASS	100%

五、归因合理性内部人工预评

评分性质：本节是提交前质量控制，不是赛事官方评分。内部建议合格线为 80 分。

表 5 报告归因合理性内部人工评分标准

评分维度	权重	评审重点
数据与方向一致性	30	数值、方向、贡献度与结构化计算一致
证据相关性与可追溯性	25	证据来源明确，能回溯到数据或知识文档
因果边界与缺失披露	25	不把相关性写成果因，不用缺失数据作结论
业务解释与可执行性	20	结论可读，核查建议具体并受审批控制

表 6 三份报告归因合理性内部人工评分分数

场景	数据	证据	边界	执行	总分
银黄口服液 2026-05	29	23	23	18	93
板蓝根颗粒 2026-05	29	23	24	18	94
六味地黄胶囊 2026-03	30	23	25	18	96
平均	29.33	23.00	24.00	18.00	94.33

人工预评依据：

- (1) **银黄口服液**：同时说明金银花单位消耗成本和市场价同向变化，并明确市场行情不等于企业实际采购价；建议继续核验采购量价、领退料和工艺收率。
- (2) **板蓝根颗粒**：在缺少企业实际采购单价和采购量时，没有输出量价差或已确认采购原因；核查方向与缺失证据相匹配。
- (3) **六味地黄胶囊**：同时披露设备维修事件和单位成本下降事实，未把设备故障写成单位成本上涨原因，也未直接分摊 8,500 元维修费，因果边界最完整。

六、三场景详细结果

6.1 银黄口服液 | 2026-05 对比 2026-04

表 7 银黄口服液报告详细结果

验收项	标准结果	结论
单位成本	10.90→11.21 元/盒	增加 0.31 元/盒，环比 2.84%
材料贡献度	67.09%	材料总成本增加 34,000.00 元
金银花单位消耗成本	+0.15 元/盒	由结构化材料明细重算
金银花市场价	130→138 元/kg	市场环比 6.15%
两厂单位成本差异	-0.39 元/盒	一厂低于二厂，成本更有利

允许结论与边界：

材料是最大成本要素，金银花单位消耗成本与市场价同期上升。市场行情不等于企业实际采购价，不得写成已经证实的采购因果。

自动结果：PASS | 三步法格式：3/3 | 模拟 RPA：sent, HTTP 200

6.2 板蓝根颗粒 | 2026-05 对比 2026-04

表 8 板蓝根颗粒报告详细结果

验收项	标准结果	结论
单位成本	7.24→7.47 元/盒	增加 0.23 元/盒，环比 3.18%
材料贡献度	69.90%	材料总成本增加 36,640.00 元
板蓝根单位消耗成本	+0.15 元/盒	由结构化材料明细重算
板蓝根市场价	29.5→32 元/kg	市场环比 8.47%
两厂单位成本差异	-0.50 元/盒	一厂低于二厂，成本更有利

允许结论与边界：

材料及板蓝根相关成本同期上升，但缺少企业实际采购单价和采购量时，不得写成量价差或已证实的采购原因。

自动结果：PASS | 三步法格式：3/3 | 模拟 RPA：sent, HTTP 200

6.3 六味地黄胶囊 | 2026-03 对比 2026-02

表 9 六味地黄胶囊报告详细结果

验收项	标准结果	结论
产量	环比+25.00%	复产后产量增加
单位成本	17.60→17.02 元/盒	下降 0.58 元/盒，环比-3.30%
材料贡献度	71.77%	材料总成本增加 73,850.00 元
三项成本要素	均下降	方向与总单位成本一致
两厂单位成本差异	-1.16 元/盒	一厂低于二厂，成本更有利
设备事件	胶囊填充机故障及维修	仅作背景，不量化影响

允许结论与边界：

设备文档和成本数据两项事实同时存在；当月单位成本实际下降，不能把设备故障写成上涨原因，也不能将 8,500 元维修费直接分摊到本产品。

自动结果：PASS | 三步法格式：3/3 | 模拟 RPA：sent, HTTP 200

七、RPA 与受控大模型验收

三个场景的整改候选均先通过 Schema 校验，并保留人工审批门。测试审批后，模拟 RPA 接口三次返回 HTTP 200，任务状态均为 sent，RPA 触发成功率为 100.00%。任务使用评测专用身份，未向生产系统发送消息。

通义千问黄金验收覆盖 3 个场景、每场景 35 项，共 105 项检查全部通过。大模型只能改写受控叙述与建议字段；确定性金额、百分比、事实表、知识引用、任务编号、责任部门和来源字段受到保护。模型不可用或调用失败时，系统回退到确定性模板。

八、结论与提交判定

提交判定：PASS

三个指定场景的报告结构完整度、对标三步法格式正确率和 RPA 触发成功率均为 100.00%；真实大模型黄金验收 3/3 通过；全量回归 213 项中 211 项通过、2 项按设计跳过、0 项失败。内部人工归因预评平均 94.33 分，仅用于提交前质量控制，不替代赛事评委的官方评分。